NGÂN HÀNG NHÀ NƯỚC VIỆT NAM **BỘ GIÁO DỤC VÀ ĐÀO TẠO**

TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH

MÔN HỌC: KHAI PHÁ DỮ LIỆU

ĐỀ TÀI: DỰ ĐOÁN GIÁ CỔ PHIẾU
(Stock Price Prediction)

Sinh viên thực hiện: Đào Việt Anh
Lê Nguyên Khôi
Nguyễn Thị Nhã Phương
Nguyễn Phan Quỳnh Thy
Trần Thị Trúc Xinh
Nguyễn Khánh Dương

Lớp: DAT704_2511_1_D03
Giảng viên hướng dẫn: Vương Trọng Nhân

NGÂN HÀNG NHÀ NƯỚC VIỆT NAM BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH

MÔN HỌC: KHAI PHÁ DỮ LIỆU

ĐỀ TÀI: DỰ ĐOÁN GIÁ CỔ PHIẾU
(Stock Price Prediction)

Sinh viên thực hiện: Đào Việt Anh
Lê Nguyên Khôi
Nguyễn Thị Nhã Phương
Nguyễn Phan Quỳnh Thy
Trần Thị Trúc Xinh
Nguyễn Khánh Dương

Lớp: DAT704_2511_1_D03

Giảng viên hướng dẫn: Vương Trọng Nhân

MỤC LỤC

LỜI CẢM ƠN **5**

1. Giới thiệu bài toán **6**

2. Giới thiệu về tập dữ liệu **6**

3. Quy trình xử lý **7**

3.1. Xử lí giá trị thiếu 8

3.2. Trích xuất đặc trưng 9

4. Giới thiệu về các công cụ, thuật toán, kĩ thuật **9**

4.1 Các thuật toán 9

4.1.1 Mô hình ARIMA 9

4.1.2 Mô hình Random Forest 10

4.1.3 Mô hình LSTM 13

4.2. Công cụ kỹ thuật 15

5. Kết quả thực nghiệm **15**

5.1. Thuật toán ARIMA 15

5.2. Mô hình LTSM 18

5.3. Mô hình Random Forest 19

5.4. So sánh ba mô hình 20

5.4.1. Phân tích định lượng và Độ chính xác 20

5.4.2. Khả năng khái quát hóa và Quy mô 21

6. Kết luận và hướng phát triển **21**

6.1. Kết luận 21

6.2. Hướng phát triển đề tài 22

TÀI LIỆU THAM KHẢO **23**

BẢNG PHÂN CÔNG NHIỆM VỤ

Họ và tên	MSSV	Nhiệm vụ	Mức độ hoàn thành
Nguyễn Khánh Dương (Nhóm trưởng)	030239230036	Xây dựng mô hình LSTM	100%
Lê Nguyên Khôi	030239230093	Xây dựng mô hình Random Forest	100%
Trần Thị Trúc Xinh	030239230298	Xây dựng mô hình ARIMA	100%
Nguyễn Phan Quỳnh Thy	030239230241	Giới thiệu bài toán; Giới thiệu data set; Định dạng file báo cáo	100%
Nguyễn Thị Nhã Phương	030239230194	Quy trình xử lý; Giới thiệu về các công cụ, thuật toán, kĩ thuật	100%
Đào Việt Anh	030239230005	Kết quả thực nghiệm; Kết luận & hướng phát triển	100%

LỜI CẢM ƠN

Lời đầu tiên, nhóm thực hiện đề tài **"Dự đoán giá cổ phiếu (Stock Price Prediction)"** xin gửi lời cảm ơn chân thành và sâu sắc nhất đến thầy **Vương Trọng Nhân**. Trong suốt quá trình học tập và thực hiện bài nghiên cứu này, chúng em đã nhận được sự hướng dẫn tận tình, những góp ý chuyên môn quý báu cũng như những kiến thức nền tảng quan trọng về Khai phá dữ liệu từ thầy. Đó là động lực và là kim chỉ nam giúp nhóm có thể hoàn thành tốt các mục tiêu đề ra.

Thông qua quá trình nghiên cứu và thực nghiệm so sánh giữa ba mô hình ARIMA, Random Forest và LSTM trên dữ liệu S&P 500 , nhóm chúng em đã có cơ hội quý giá để áp dụng lý thuyết vào thực tiễn, hiểu rõ hơn về cách xử lý dữ liệu tài chính phức tạp và nắm vững cơ chế vận hành của các thuật toán học máy hiện đại.

Mặc dù đã đầu tư nhiều tâm huyết và nỗ lực để hoàn thiện bài tiểu luận, nhưng do kiến thức và kinh nghiệm thực tế của nhóm còn hạn chế, bài làm chắc chắn sẽ không tránh khỏi những thiếu sót. Nhóm chúng em rất mong nhận được những nhận xét và góp ý từ thầy để chúng em có thể rút kinh nghiệm và hoàn thiện hơn trong những bài nghiên cứu tiếp theo.

Chúng em xin chân thành cảm ơn!

1. Giới thiệu bài toán

Thị trường chứng khoán là một trong những thị trường tài chính quan trọng nhất, phản ánh tình hình kinh tế và hoạt động của các doanh nghiệp. Giá cổ phiếu biến động liên tục theo thời gian và chịu ảnh hưởng của nhiều yếu tố như kết quả kinh doanh, chính sách kinh tế vĩ mô, lãi suất, tâm lý nhà đầu tư và các sự kiện bất ngờ. Chính vì tính chất phức tạp, phi tuyến và khó dự đoán này, việc xây dựng các mô hình dự báo giá cổ phiếu luôn là một bài toán thách thức nhưng có giá trị ứng dụng cao trong thực tiễn.

"Dự đoán giá cổ phiếu (Stock Price Prediction)" là bài toán sử dụng dữ liệu lịch sử để ước lượng xu hướng và giá trị của cổ phiếu trong tương lai, nhằm hỗ trợ nhà đầu tư trong việc ra quyết định đầu tư như mua, bán hoặc nắm giữ cổ phiếu. Trong những năm gần đây, cùng với sự phát triển mạnh mẽ của khoa học dữ liệu và trí tuệ nhân tạo, nhiều phương pháp từ thống kê truyền thống đến các mô hình học máy (Machine Learning) và học sâu (Deep Learning) đã được áp dụng để giải quyết bài toán này.

Các mô hình thống kê như ARIMA có ưu điểm trong việc phân tích chuỗi thời gian tuyến tính và thể hiện rõ tính mùa vụ, xu hướng của dữ liệu. Trong khi đó, các mô hình học máy như Random Forest có khả năng khai thác mối quan hệ phi tuyến giữa các đặc trưng tài chính. Đặc biệt, các mô hình học sâu như LSTM (Long Short-Term Memory) được thiết kế chuyên biệt cho dữ liệu chuỗi thời gian, có khả năng ghi nhớ thông tin dài hạn và nắm bắt các mẫu biến động phức tạp của giá cổ phiếu.

Xuất phát từ những vấn đề trên, đề tài tập trung vào việc xây dựng và so sánh hiệu quả của ba mô hình ARIMA, LSTM và Random Forest trong bài toán dự đoán giá cổ phiếu. Thông qua việc trích xuất các đặc trưng từ dữ liệu tài chính lịch sử và đánh giá mô hình bằng các tiêu chí định lượng, nghiên cứu nhằm xác định mô hình phù hợp nhất cho việc dự báo giá cổ phiếu dựa trên dữ liệu S&P 500.

2. Giới thiệu về tập dữ liệu

Tập dữ liệu được sử dụng trong nghiên cứu là S&P 500 Stock Data, bao gồm dữ liệu lịch sử giá của các cổ phiếu thuộc chỉ số S&P 500 – một trong những chỉ số chứng khoán đại diện và có ảnh hưởng lớn nhất trên thị trường chứng khoán Hoa Kỳ. Chỉ số S&P 500 phản ánh biến động của 500 công ty có vốn hóa lớn, hoạt động trong nhiều lĩnh vực khác nhau, do đó dữ liệu có tính đại diện cao cho xu hướng chung của thị trường.

Dữ liệu thường được thu thập theo chu kỳ ngày giao dịch và bao gồm các thuộc tính cơ bản như:

- Open: Giá mở cửa của cổ phiếu trong ngày giao dịch.
- High: Giá cao nhất trong ngày.
- Low: Giá thấp nhất trong ngày.
- Close: Giá đóng cửa của cổ phiếu.
- Volume: Khối lượng cổ phiếu được giao dịch.

Các thuộc tính này phản ánh trực tiếp diễn biến giá và mức độ sôi động của thị trường trong từng phiên giao dịch. Trong nghiên cứu, giá đóng cửa (Close) thường được lựa chọn làm biến mục tiêu do đây là mức giá được sử dụng phổ biến để đánh giá giá trị cổ phiếu vào cuối phiên.

Từ dữ liệu gốc, quá trình tiền xử lý được thực hiện nhằm đảm bảo chất lượng dữ liệu đầu vào cho mô hình. Các bước tiền xử lý bao gồm xử lý giá trị thiếu, chuẩn hóa dữ liệu và sắp xếp dữ liệu theo thứ tự thời gian. Bên cạnh đó, các đặc trưng tài chính bổ sung cũng được trích xuất từ dữ liệu lịch sử như tỷ suất sinh lợi (return), đường trung bình động (Moving Average), độ biến động (volatility) và các chỉ báo kỹ thuật khác. Những đặc trưng này giúp mô hình học được các xu hướng và hành vi biến động của giá cổ phiếu một cách hiệu quả hơn.

Sau khi hoàn tất quá trình tiền xử lý và trích xuất đặc trưng, dữ liệu được chia thành tập huấn luyện và tập kiểm tra theo trục thời gian nhằm đảm bảo tính thực tế của bài toán dự báo. Tập dữ liệu này sau đó được sử dụng để huấn luyện và so sánh hiệu quả dự đoán của các mô hình ARIMA, Random Forest và LSTM trong nghiên cứu.

3. Quy trình xử lý

Xử lý dữ liệu là bước rất quan trọng trong lĩnh vực máy học tài chính, vì nó ảnh hưởng trực tiếp đến độ chính xác của mô hình. Với dữ liệu S&P 500 vốn nhiều nhiễu và biến động phức tạp, cần xây dựng một quy trình xử lý rõ ràng và chặt chẽ, không chỉ để dự báo giá mà còn hỗ trợ ra quyết định cho nhà đầu tư.

Trong đó, việc thu thập dữ liệu phải được chú trọng trước tiên. Dữ liệu cần đủ tốt và đủ dài (khoảng 5-10 năm) để phản ánh các giai đoạn khác nhau của nền kinh tế như tăng trưởng hay suy

thoái. Điều này giúp mô hình nhận diện được xu hướng dài hạn và các chu kỳ lặp lại của thị trường, đồng thời vẫn phù hợp với bối cảnh hiện tại.

Dữ liệu tài chính có nhiều đặc điểm khiến việc dự báo trở nên khó khăn:

- Tính phi tuyến tính: Giá thị trường không thay đổi theo quy luật tuyến tính đơn giản mà phản ánh hành vi phức tạp của nhà đầu tư.
- Độ nhiễu cao: Giá có thể biến động mạnh do tin tức ngắn hạn hoặc yếu tố tâm lý.
- Tính không dừng: Giá thường có xu hướng tăng hoặc giảm theo thời gian, khiến các đặc tính thống kê không ổn định.
- Sự phụ thuộc theo thời gian: Giá hôm nay chịu ảnh hưởng trực tiếp từ các ngày trước đó.

Những đặc điểm này đòi hỏi phải lựa chọn và so sánh nhiều nhóm mô hình khác nhau để đánh giá hiệu quả dự báo trong các điều kiện thị trường khác nhau.

3.1. Xử lí giá trị thiếu

Trong dữ liệu chuỗi thời gian, sự liên tục đóng vai trò then chốt, đặc biệt với các mô hình tự hồi quy như ARIMA và LSTM, vốn hoạt động dựa trên mối quan hệ giữa các giá trị trong quá khứ (độ trễ).

Các giá trị thiếu trong dữ liệu chứng khoán thường xuất hiện vào các ngày cuối tuần hoặc ngày lễ. Đây là dạng thiếu dữ liệu có cấu trúc (Structurally Missing Data).

Phương pháp xử lý:

- Loại bỏ dữ liệu (Dropping): Với những ngày thị trường không giao dịch như cuối tuần hay ngày lễ, cách xử lý an toàn nhất là loại bỏ các dòng dữ liệu này, vì thực tế không có hoạt động mua bán diễn ra.
- Lấp đầy dữ liệu (Imputation): Nếu dữ liệu bị thiếu trong các ngày giao dịch, nên sử dụng phương pháp Forward Fill, tức là lấy giá gần nhất trước đó để điền vào. Cách này phù hợp với logic thị trường tài chính: khi chưa có thông tin mới, mức giá hợp lý nhất vẫn là mức giá của lần giao dịch gần nhất. Việc dùng giá trị trung bình hay nội suy tuyến tính, đặc biệt là sử dụng dữ liệu trong tương lai để điền cho quá khứ, có thể làm sai lệch mô hình do vi phạm nguyên tắc nhân quả và gây rò rỉ dữ liệu.

Bước xử lý	Nội dung	Ý nghĩa
Làm sạch dữ liệu	Loại bỏ hoặc điền các giá trị bị thiếu.	Giúp dữ liệu đầy đủ, không bị gián đoạn khi tính các đặc trưng theo thời gian (lag, rolling…).
Chuẩn hóa dữ liệu	Áp dụng Min-Max Scaling để đưa dữ liệu về cùng một khoảng giá trị.	Tránh tình trạng biến có giá trị lớn ảnh hưởng quá mức đến mô hình so với các biến khác.
Chuyển đổi định dạng	Chuyển cột Date sang kiểu datetime và sắp xếp theo thời gian.	Đảm bảo dữ liệu được sắp đúng thứ tự thời gian khi phân tích và xây dựng mô hình..
Chia tập dữ liệu	Chia dữ liệu theo trình tự thời gian, không xáo trộn.	Tránh việc mô hình sử dụng thông tin tương lai để dự đoán quá khứ.

3.2. Trích xuất đặc trưng

Dữ liệu giá thô thường chưa đủ để mô hình nhận diện trạng thái thị trường. Do đó, nghiên cứu này sử dụng các chỉ số kỹ thuật để bổ sung thông tin cho mô hình:

- Trung bình động (SMA-Simple Moving Average, EMA-Exponential Moving Average): Giúp xác định xu hướng giá.
- RSI (Relative Strength Index): Đánh giá trạng thái quá mua hoặc quá bán.
- MACD: Nhận diện sự thay đổi cường độ xu hướng.
- Bollinger Bands: Xác định biên độ dao động dựa trên độ lệch chuẩn quanh đường trung bình.
- Lag features: Cung cấp thông tin giá trong các ngày trước đó (t-1, t-2) để cung cấp bối cảnh lịch sử cho mô hình.

Các đặc trưng này giúp mô hình hiểu rõ hơn động lực vận động của thị trường.

4. Giới thiệu về các công cụ, thuật toán, kĩ thuật

4.1 Các thuật toán

4.1.1 Mô hình ARIMA

ARIMA (AutoRegressive Integrated Moving Average) là mô hình thống kê truyền thống được sử dụng phổ biến trong dự báo chuỗi thời gian tài chính, đặc biệt phù hợp với các bài toán dự báo

ngắn hạn.

Về bản chất, ARIMA khai thác mối quan hệ tuyến tính giữa giá trị hiện tại của chuỗi và các giá trị trong quá khứ, kết hợp với thành phần sai số dự báo. Mô hình được xác định bởi ba tham số (p, d, q), trong đó tham số p thể hiện mức độ phụ thuộc của giá trị hiện tại vào các giá trị trễ, tham số d cho biết số lần sai phân cần thực hiện để chuỗi dữ liệu đạt tính dừng, và tham số q biểu diễn mức độ ảnh hưởng của sai số dự báo trong quá khứ.

Trước khi xây dựng mô hình ARIMA, dữ liệu cần được kiểm tra tính dừng bằng kiểm định Augmented Dickey-Fuller (ADF). Trong trường hợp chuỗi không dừng, phép sai phân bậc một được áp dụng nhằm loại bỏ xu hướng dài hạn và đưa chuỗi về trạng thái ổn định hơn. Đây là bước bắt buộc để đảm bảo các giả định thống kê của mô hình ARIMA được thỏa mãn.

Ưu điểm lớn nhất của ARIMA là cấu trúc toán học rõ ràng và khả năng giải thích cao, có thể dễ dàng phân tích mức độ ảnh hưởng của từng bậc trễ và sai số đến kết quả dự báo. Tuy nhiên, do giả định mối quan hệ tuyến tính, ARIMA gặp nhiều hạn chế khi thị trường xuất hiện các biến động phi tuyến mạnh hoặc các cú sốc bất thường. Trong những giai đoạn thị trường biến động cao, mô hình này thường phản ứng chậm và cho sai số lớn.

4.1.2 Mô hình Random Forest

Random Forest là một thuật toán học máy có giám sát, thuộc nhóm mô hình tập hợp (Ensemble Learning). Thuật toán này hoạt động bằng cách xây dựng nhiều cây quyết định (Decision Trees) độc lập, sau đó kết hợp kết quả dự đoán của các cây này để đưa ra kết quả cuối cùng. Mỗi cây quyết định được huấn luyện trên một tập con ngẫu nhiên của dữ liệu và chỉ xét một tập con các đặc trưng tại mỗi điểm chia. Kết quả dự báo cuối cùng của Random Forest là trung bình của các dự báo từ các cây thành phần. Nhờ cách tiếp cận này, Random Forest giúp mô hình trở nên ổn định hơn và chính xác hơn so với việc chỉ sử dụng một cây quyết định đơn lẻ.

Trong bài toán dự báo chỉ số S&P 500, Random Forest được sử dụng để khai thác các mối quan hệ phi tuyến giữa các đặc trưng kỹ thuật như RSI, MACD, Bollinger Bands, trung bình động và các biến trễ. Khác với ARIMA, mô hình này không yêu cầu dữ liệu phải dừng và cũng không đưa ra giả định cụ thể về phân phối của dữ liệu đầu vào.

Ưu điểm nổi bật của Random Forest là khả năng xử lý tốt dữ liệu có độ nhiễu cao, vốn là đặc trưng phổ biến của thị trường tài chính. Nhờ cơ chế lấy mẫu ngẫu nhiên và trung bình hóa kết quả,

mô hình có khả năng giảm hiện tượng quá khớp và cho kết quả dự báo ổn định hơn so với cây quyết định đơn lẻ.

Tuy nhiên, Random Forest không tự động ghi nhớ thứ tự thời gian của dữ liệu. Do đó, để áp dụng mô hình này cho chuỗi thời gian, cần xây dựng các đặc trưng trễ nhằm phản ánh ảnh hưởng của các thời điểm trước đó đến giá trị hiện tại. Ngoài ra, Random Forest có tính chất "hộp đen", khiến việc giải thích chi tiết cơ chế ra quyết định trở nên khó khăn hơn so với ARIMA.

Decision Tree (Cây quyết định) là một mô hình học máy có thể sử dụng cho cả bài toán phân loại và hồi quy. Cấu trúc của Decision Tree có dạng một sơ đồ luồng, trong đó dữ liệu được chia dần qua các nút dựa trên điều kiện của một thuộc tính cụ thể. Decision Tree có ưu điểm là dễ hiểu và dễ diễn giải, tuy nhiên lại tồn tại nhiều hạn chế khi áp dụng vào dữ liệu tài chính có độ nhiễu cao.

Cấu trúc cơ bản của một cây quyết định bao gồm:

- Nút gốc (Root Node): Nút bắt đầu của cây, chứa toàn bộ tập dữ liệu ban đầu.
- Nút quyết định (Decision Node): Các nút trung gian, tại đó dữ liệu được chia dựa trên một điều kiện cụ thể (ví dụ: RSI > 70).
- Nhánh (Branch): Kết nối giữa các nút, đại diện cho kết quả của một phép kiểm tra.
- Nút lá (Leaf / Terminal Node): Nút cuối cùng của cây, chứa giá trị dự đoán (đối với hồi quy) hoặc nhãn dự đoán (đối với phân loại).
- Chia nhánh (Splitting): Quá trình chia một nút thành các nút con dựa trên tiêu chí tối ưu như giảm sai số hoặc tăng Information Gain.
- Cắt tỉa (Pruning): Quá trình loại bỏ các nhánh không cần thiết nhằm giảm hiện tượng quá khớp.

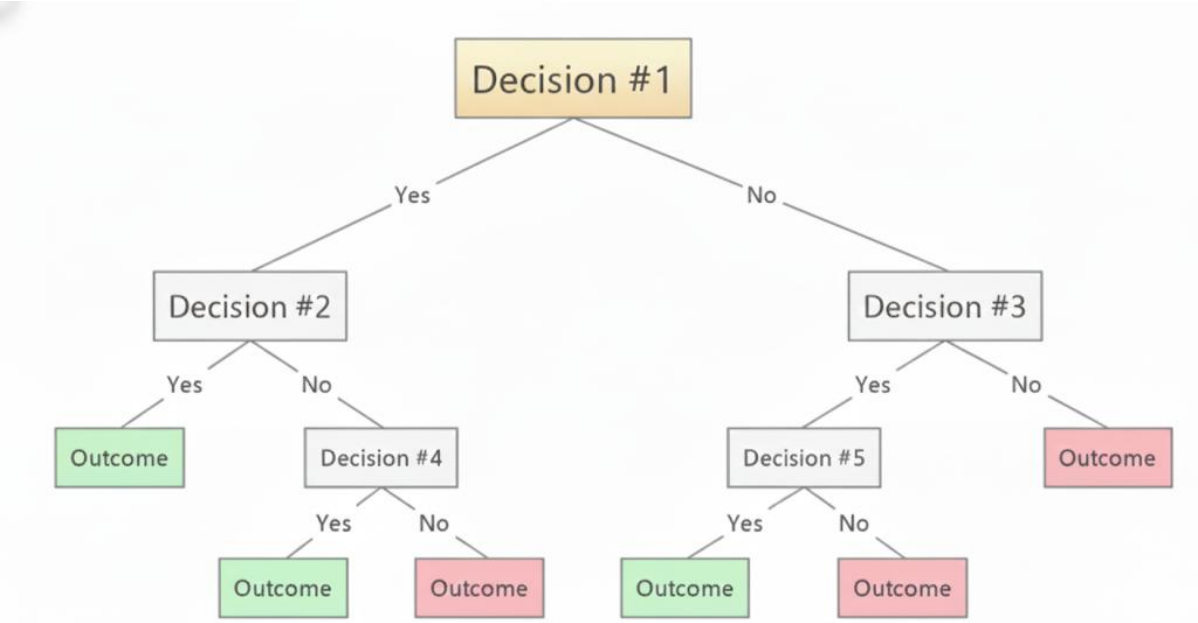

Ensemble Learning là phương pháp kết hợp kết quả từ nhiều mô hình khác nhau nhằm cải thiện độ chính xác và độ ổn định của dự đoán. Random Forest sử dụng kỹ thuật Bagging (Bootstrap Aggregating), trong đó:

- Mỗi cây quyết định được huấn luyện trên một tập con dữ liệu được lấy mẫu ngẫu nhiên có hoàn lại từ tập huấn luyện ban đầu.
- Tại mỗi nút chia, mô hình chỉ xét một tập con ngẫu nhiên các đặc trưng thay vì toàn bộ đặc trưng.

Cơ chế này giúp tạo ra các cây quyết định đa dạng và ít phụ thuộc lẫn nhau, từ đó làm giảm phương sai của mô hình tổng thể và hạn chế hiện tượng quá khớp.

Việc sử dụng Random Forest được ưu tiên hơn so với Decision Tree đơn lẻ do các hạn chế sau của cây quyết định:

- Tính không ổn định: Một thay đổi nhỏ trong dữ liệu đầu vào có thể làm thay đổi hoàn toàn cấu trúc của cây.
- Độ chính xác chưa cao: Cây đơn lẻ thường dễ bị quá khớp với dữ liệu huấn luyện.
- Thiên lệch Information Gain: Decision Tree có xu hướng ưu tiên các thuộc tính có nhiều mức phân loại.

– Khó xử lý dữ liệu nhiễu: Dữ liệu tài chính thường chứa nhiều biến động ngẫu nhiên, khiến cây dễ học nhầm nhiễu.

Random Forest khắc phục các hạn chế trên bằng cách kết hợp nhiều cây khác nhau, từ đó tạo ra dự đoán ổn định hơn và phù hợp hơn với dữ liệu thị trường chứng khoán.

Một số ưu điểm và hạn chế của Random Forest trong dự báo tài chính như:

– Ưu điểm:

- Xử lý tốt các mối quan hệ phi tuyến giữa các đặc trưng.
- Ít nhạy cảm với nhiễu so với mô hình đơn lẻ.
- Không yêu cầu giả định dữ liệu phải dừng.
- Hoạt động hiệu quả khi số lượng đặc trưng lớn.

– Hạn chế:

- Không tự động ghi nhớ thứ tự thời gian của dữ liệu.
- Khó giải thích chi tiết cơ chế dự đoán (tính chất "hộp đen").
- Chi phí tính toán cao hơn so với Decision Tree đơn lẻ.

4.1.3 Mô hình LSTM

LSTM (Long Short-Term Memory) là một dạng mạng nơ-ron nhân tạo thuộc nhóm Recurrent Neural Network (RNN), được thiết kế nhằm mô phỏng khả năng ghi nhớ dài hạn của bộ não con người. Điểm khác biệt quan trọng của LSTM so với các mô hình RNN truyền thống nằm ở khả năng lưu giữ và khai thác thông tin từ quá khứ xa, thay vì chỉ dựa vào các quan sát gần nhất.

Trong bài toán dự báo thị trường chứng khoán, giá cổ phiếu tại thời điểm hiện tại không chỉ chịu ảnh hưởng bởi giá của ngày hôm trước, mà còn bị chi phối bởi các xu hướng đã hình thành từ nhiều tuần hoặc thậm chí nhiều tháng trước đó. Nhờ cơ chế ghi nhớ đặc biệt, LSTM có thể nắm bắt được các mối quan hệ dài hạn này, trong khi các mô hình thông thường dễ bị "quên" thông tin cũ khi chuỗi dữ liệu trở nên dài.

Cơ chế vận hành của LSTM: Quên - Nhập - Xuất thông tin.

Sức mạnh chủ yếu của LSTM đến từ cấu trúc ô nhớ (Cell State), có thể hình dung như một dòng

thông tin chạy xuyên suốt theo thời gian. Để kiểm soát luồng thông tin này, LSTM sử dụng ba cổng chính, hoạt động như các bộ lọc thông minh:

- Cổng Quên (Forget Gate): Cổng này quyết định những thông tin nào từ quá khứ không còn giá trị và cần bị loại bỏ khỏi bộ nhớ. Tương tự như việc bỏ qua các thông tin đã lỗi thời hoặc các biến động ngẫu nhiên không còn ảnh hưởng đến xu hướng hiện tại.
- Cổng Nhập (Input Gate): Cổng nhập có nhiệm vụ lựa chọn những thông tin mới quan trọng để cập nhật vào bộ nhớ. Ví dụ, các dữ liệu mới như kết quả kinh doanh hoặc biến động giá gần đây sẽ được cân nhắc để bổ sung vào trạng thái bộ nhớ của mô hình.
- Cổng Xuất (Output Gate): Dựa trên thông tin đang được lưu trữ trong bộ nhớ, cổng xuất quyết định phần nào sẽ được sử dụng để tạo ra giá trị dự báo tại thời điểm hiện tại.

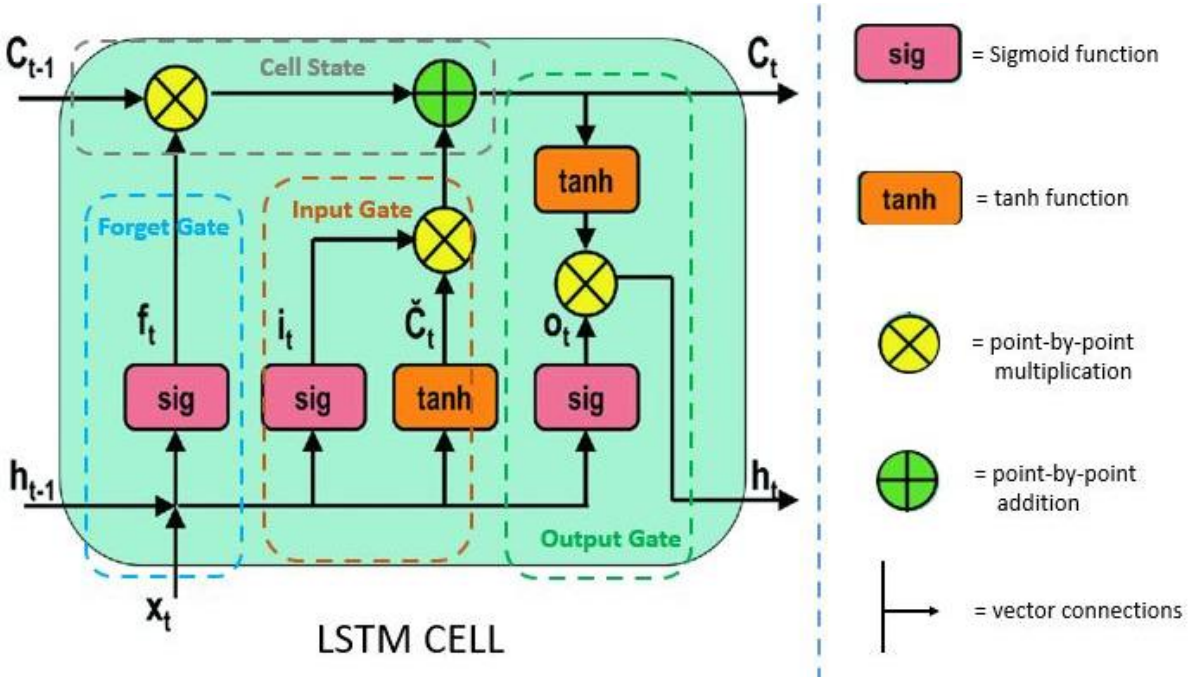

Nhờ sự phối hợp của ba cổng này, LSTM có khả năng giữ lại các kí ức quan trọng và loại bỏ các thông tin nhiễu, từ đó nâng cao độ chính xác khi dự báo trong môi trường tài chính nhiều biến động.

Một yếu tố quan trọng khi huấn luyện mô hình LSTM là kích thước cửa sổ thời gian (Window Size), hay số bước nhìn lại trong quá khứ. Có thể hiểu LSTM như một nhà đầu tư phân tích biểu đồ giá trước khi ra quyết định:

- Nếu cửa sổ quá ngắn (ví dụ chỉ xem xét 5 ngày gần nhất), mô hình dễ phản ứng quá mức với các biến động nhỏ và bỏ lỡ xu hướng dài hạn.
- Nếu cửa sổ quá dài (ví dụ xem xét dữ liệu của cả năm), mô hình có thể bị ảnh hưởng bởi quá nhiều thông tin cũ không còn phù hợp.

Trong thực tế, việc sử dụng cửa sổ từ 30 đến 60 ngày giao dịch gần nhất thường giúp LSTM đạt được sự cân bằng tốt giữa việc ghi nhớ xu hướng và phản ứng với thay đổi mới của thị trường.

4.2. Công cụ kỹ thuật

- Ngôn ngữ Python: Nền tảng chính nhờ hệ sinh thái thư viện phong phú cho khoa học dữ liệu.
- Pandas & NumPy: Dùng để cấu trúc hóa dữ liệu dạng bảng và thực hiện các phép toán ma trận phức tạp.
- Scikit-learn: Cung cấp công cụ cho mô hình Random Forest và các kỹ thuật chuẩn hóa, chia dữ liệu.
- TensorFlow/Keras: Thư viện chuyên dụng để xây dựng và huấn luyện mạng neural LSTM.
- Statsmodels: Sử dụng để thực hiện kiểm định ADF (kiểm tra tính dừng) và triển khai mô hình ARIMA.

5. Kết quả thực nghiệm

5.1. Thuật toán ARIMA

```
------------------------------------------------
KẾT QUẢ ĐÁNH GIÁ (GOOG):
1. RMSE (Sai số chuẩn): 29.34
2. MAE (Sai số tuyệt đối): 24.81
3. MAPE (Sai số phần trăm): 20.88%
------------------------------------------------
```

Kết quả đánh giá mô hình ARIMA đối với mã cổ phiếu GOOG cho thấy chỉ số sai số phần trăm tuyệt đối trung bình (MAPE) đạt mức 20.88%, đo lường phần trăm sai số trung bình giữa giá trị dự báo và giá trị thực tế cho thấy rằng mức sai số này là khá cao. Các chỉ số sai số tuyệt đối (MAE) và sai số bình phương trung bình (RMSE) lần lượt dừng ở mức 24.81 và 29.34, phản ánh

một độ lệch nhất định so với giá trị thực tế, chỉ số RMSE cao hơn MAE thể hiển rằng mô hình chưa chắc chắc trước những phiên có giao động lớn của thị trường.

Mặc dù ARIMA đã thể hiện được khả năng dự báo xu hướng cơ bản, mức sai số này cho thấy mô hình còn hạn chế trong việc xử lý các biến động mạnh và tính phi tuyến của thị trường chứng khoán.

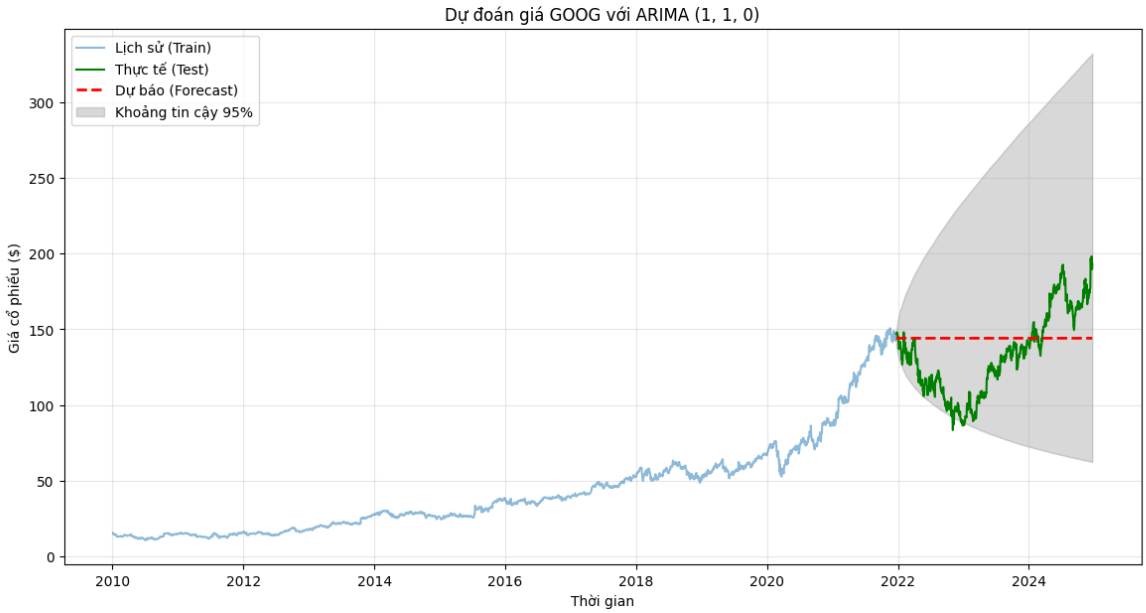

Biểu đồ trực quan hóa kết quả của thuật toán ARIMA.

Quan sát biểu đồ, hạn chế điển hình của mô hình ARIMA(1,1,0) khi dự báo dài hạn là đường dự báo (màu đỏ) nhanh chóng trở thành một đường thẳng nằm ngang. Hiện tượng này cho thấy mô hình đã rơi vào trạng thái "Random Walk", tức là chỉ lấy giá trị trung bình gần nhất làm cơ sở mà hoàn toàn mất đi khả năng bắt kịp xu hướng tăng trưởng thực tế của cổ phiếu trong giai đoạn 2023-2024.

Bên cạnh đó, khoảng tin cậy 95% (vùng màu xám) mở rộng rất nhanh theo hình "phễu", phản ánh mức độ rủi ro và sự bất định tăng dần theo thời gian. Trong khi mô hình dự báo đi ngang, giá thực tế của GOOG đã bứt phá mạnh mẽ lên gần 200 USD, chạm sát mép trên của khoảng tin cậy. Điều này chứng minh rằng các mô hình thống kê tuyến tính như ARIMA không đủ linh hoạt để xử lý tính phi tuyến, nhiễu thị trường, cũng như các đợt sụt giảm sâu hay phục hồi mạnh mẽ của thị trường chứng khoán.

```
--- Bắt đầu chấm điểm mô hình ARIMA trên danh mục (Tổng: 172 mã) --
OK | MAPE: 56.93%
OK | MAPE: 54.09%
OK | MAPE: 8.93%
OK | MAPE: 23.89%
OK | MAPE: 49.23%
OK | MAPE: 23.51%
OK | MAPE: 11.38%
OK | MAPE: 47.83%
OK | MAPE: 8.64%
OK | MAPE: 87.15%
OK | MAPE: 14.38%
OK | MAPE: 11.74%
OK | MAPE: 20.04%
OK | MAPE: 76.22%
OK | MAPE: 16.90%
OK | MAPE: 26.66%
OK | MAPE: 5.21%
OK | MAPE: 10.15%
OK | MAPE: 26.86%
OK | MAPE: 24.34%
OK | MAPE: 86.85%
OK | MAPE: 17.37%
OK | MAPE: 22.56%
OK | MAPE: 21.77%
OK | MAPE: 11.42%
OK | MAPE: 12.03%
OK | MAPE: 19.54%
OK | MAPE: 24.37%
OK | MAPE: 23.95%
OK | MAPE: 123.31%

========================================
KẾT QUẢ TRUNG BÌNH (30 mã)
MAPE: 32.24%
========================================
Đánh giá:Mô hình cần được tối ưu thêm (Poor).
```

Chỉ số MAPE trung bình đạt 32.24%, một con số được xếp loại Poor (Kém) trong tiêu chuẩn dự báo tài chính. Đáng chú ý, có sự phân hóa cực lớn trong sai số: trong khi một số mã đạt kết quả khả quan (MAPE từ 5-8%), thì vẫn tồn tại những mã có sai số vượt ngưỡng 100% (như mức 123.31%). Điều này chứng minh rằng ARIMA, với bản chất là mô hình thống kê tuyến tính, không có khả năng tự thích nghi tốt với sự đa dạng và tính biến động không đồng nhất của toàn bộ thị trường S&P 500.

Từ các kết quả định lượng & định tính nêu trên, có thể kết luận rằng mô hình ARIMA(1, 1, 0) chỉ mang tính chất tham khảo cho các biến động ngắn hạn & không đủ tin cậy để đưa ra quyết định đầu tư dài hạn. Sự thất bại trong việc bắt kịp các điểm xoay chiều (turning points) & xu hướng dài hạn của mã GOOG cho thấy nhu cầu cấp thiết của việc áp dụng các mô hình phức tạp hơn.

5.2. Mô hình LTSM

```
========================================
BÁO CÁO ĐIỂM SỐ MÔ HÌNH LSTM
Tổng số mã cổ phiếu đánh giá: 30
Điểm MAPE trung bình: 3.10%
Điểm RMSE trung bình: 4.87 USD
========================================
Đánh giá: Mô hình cực kỳ chính xác (Excellent).
```

Kết quả thực nghiệm trên danh mục 30 mã cổ phiếu cho thấy mô hình LSTM đạt hiệu suất cực kỳ ấn tượng với chỉ số MAPE trung bình chỉ ở mức 3.10%. Đây là một con số lý tưởng trong dự báo tài chính, phản ánh khả năng khớp (fit) dữ liệu gần như tuyệt đối của mô hình đối với các biến động thực tế. Với sai số bình phương trung bình RMSE là 4.87 USD, LSTM chứng minh được sự ổn định cao, không bị ảnh hưởng quá lớn bởi các giá trị ngoại lai hay những cú sốc ngắn hạn của thị trường. Mô hình được hệ thống đánh giá ở mức Excellent (Cực kỳ chính xác), vượt xa các tiêu chuẩn dự báo thông thường.

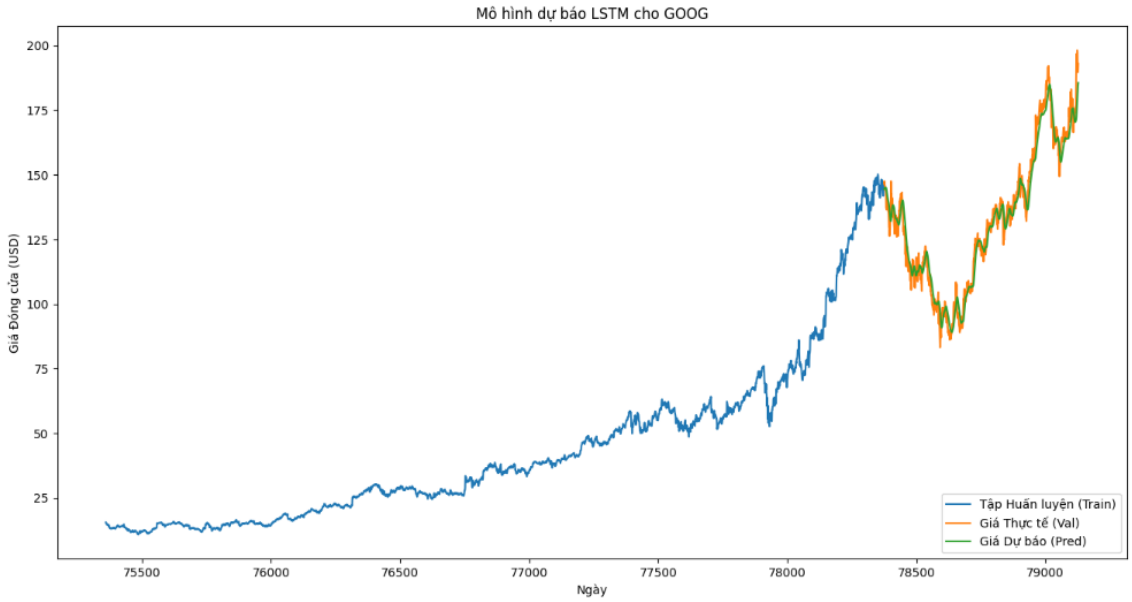

Biểu đồ trực quan hóa kết quả của mô hình LTSM.

Biểu đồ dự báo của LSTM cho thấy sự tương quan chặt chẽ giữa giá trị dự báo (màu xanh lá) và giá trị thực tế (màu cam). Khác hoàn toàn với đường dự báo đi ngang của ARIMA, mô hình LSTM đã thành công trong việc bám sát các nhịp biến động mạnh, các điểm đảo chiều và xu hướng tăng trưởng dài hạn của mã GOOG.

Về độ chính xác: Mô hình LSTM đạt chỉ số MAPE trung bình là 3.10% trên danh mục 30 mã

trong khi mô hình ARIMA có sai số lên tới 32.24%. Điều này đồng nghĩa với việc LSTM chính xác hơn gấp 10 lần so với ARIMA trong bài toán này. Cho thấy sự khác biệt về các chỉ số thống kê giữa hai phương pháp là vô cùng rõ rệt.

Về mức độ tin cậy: Với mức RMSE trung bình chỉ 4.87 USD, LSTM duy trì được sự ổn định rất cao, giúp giảm thiểu rủi ro cho nhà đầu tư khi đưa ra quyết định dựa trên dự báo.

Mô hình LSTM được xếp hạng Excellent (Cực kỳ chính xác), khẳng định đây là công cụ tối ưu nhất cho việc dự báo giá cổ phiếu trong phạm vi đề tài này. Khả năng ghi nhớ thông tin dài hạn của mạng thần kinh LSTM đã giải quyết triệt để bài toán dự báo trong thị trường đầy biến động như S&P 500.

Về độ chính xác: Mô hình LSTM đạt chỉ số MAPE trung bình là 3.10% trên danh mục 30 mã, trong khi mô hình ARIMA có sai số lên tới 32.24%. Điều này đồng nghĩa với việc LSTM chính xác hơn gấp 10 lần so với ARIMA trong bài toán này. Cho thấy sự khác biệt về các chỉ số thống kê giữa hai phương pháp là vô cùng rõ rệt.

Về mức độ tin cậy: Với mức RMSE trung bình chỉ 4.87 USD, LSTM duy trì được sự ổn định rất cao, giúp giảm thiểu rủi ro cho nhà đầu tư khi đưa ra quyết định dựa trên dự báo.

Mô hình LSTM được xếp hạng Excellent (Cực kỳ chính xác), khẳng định đây là công cụ tối ưu nhất cho việc dự báo giá cổ phiếu trong phạm vi đề tài này. Khả năng ghi nhớ thông tin dài hạn của mạng thần kinh LSTM đã giải quyết triệt để bài toán dự báo trong thị trường đầy biến động như S&P 500.

5.3. Mô hình Random Forest

```
Tổng số mã cổ phiếu đánh giá: 30
RMSE (30 stocks): 7.2874 USD
MAPE (30 stocks): 3.79%
```

Mô hình Random Forest cho thấy hiệu suất dự báo nổi bật khi được áp dụng trên quy mô lớn của danh mục S&P 500. Cụ thể, với tập đánh giá gồm 30 mã cổ phiếu, mô hình đạt MAPE = 3.79% nằm dưới ngưỡng 5% và được xếp vào nhóm Highly Accurate (rất chính xác) trong dự báo tài chính. Bên cạnh đó, RMSE = 7,29 USD phản ánh mức sai lệch tuyệt đối tương đối thấp, cho thấy

mô hình duy trì được độ ổn định và tin cậy cao ngay cả khi làm việc với dữ liệu đa dạng và có mức độ nhiễu lớn.

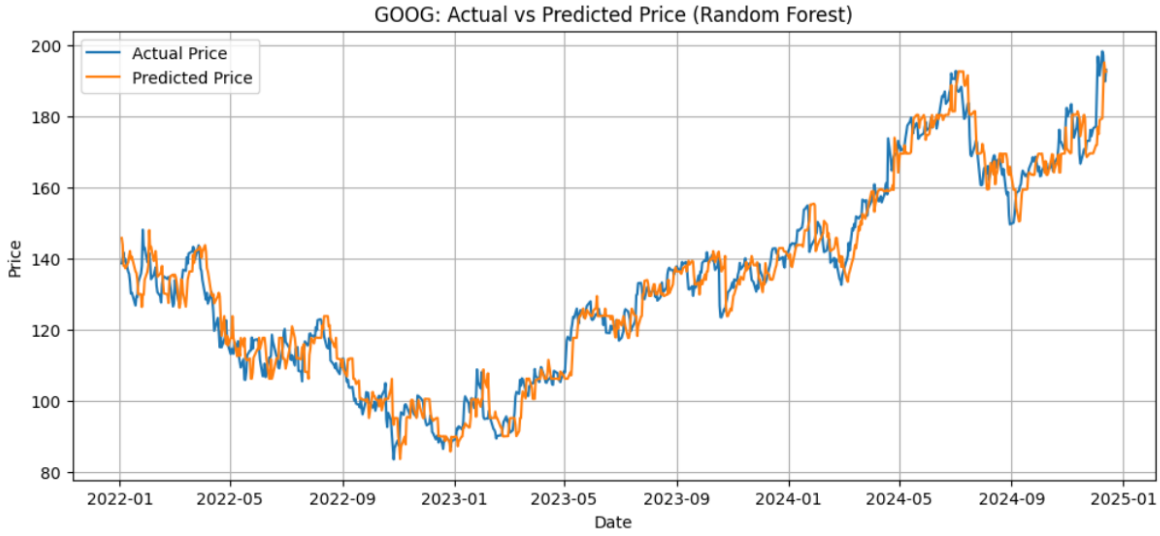

Dựa trên biểu đồ so sánh giá thực tế và giá dự báo của cổ phiếu GOOG bằng mô hình Random Forest, có thể nhận thấy đường dự báo (màu cam) bám sát rất chặt chẽ đường giá thực tế (màu xanh) trong toàn bộ giai đoạn từ đầu năm 2022 đến đầu năm 2025. Mô hình tái hiện tốt cả xu hướng dài hạn lẫn các dao động ngắn hạn, cho thấy khả năng học và phản ánh chính xác động lực thị trường.

Đáng chú ý, Random Forest không chỉ theo kịp các nhịp điều chỉnh mạnh vào cuối năm 2022 khi giá giảm xuống quanh vùng 90-100 USD, mà còn mô phỏng hiệu quả giai đoạn phục hồi và tăng trưởng rõ rệt từ năm 2023 đến cuối năm 2024, khi giá vượt mốc 180 USD. Đường dự báo hầu như không xuất hiện độ trễ đáng kể so với thực tế, phản ánh việc các đặc trưng đầu vào đã được khai thác và kết hợp hiệu quả. Kết quả này tiếp tục khẳng định ưu thế của phương pháp Ensemble Learning trong việc nắm bắt các quan hệ phi tuyến và cấu trúc phức tạp của dữ liệu tài chính.

5.4. So sánh ba mô hình

5.4.1. Phân tích định lượng và Độ chính xác

Bảng tổng hợp chỉ số của các mô hình:

Chỉ số	ARIMA (1, 1, 0)	LSTM	Random Forest
Quy mô đánh giá	30 mã cổ phiếu	30 mã cổ phiếu	30 mã cổ phiếu
MAPE trung bình	32.24%	3.10%	3.79%
RMSE trung bình	29.34 USD	4.87 USD	7.29 USD
Xếp loại hiệu suất	Cần tối ưu thêm (Poor)	Cực kỳ chính xác (Excellent)	Rất chính xác (Very Good)

Tính ổn định của LSTM: Với MAPE chỉ 3.10% và RMSE cực thấp (4.87 USD), mô hình này cho thấy sự tập trung sai số rất nhỏ. Điều này minh chứng rằng LSTM đã lọc nhiễu hiệu quả, giúp dự báo bám sát giá trị thực tế mà không bị lệch quá xa ngay cả ở những thời điểm thị trường biến động mạnh.

Sự bao quát của Random Forest: Đạt MAPE 3.79% trên quy mô 30 mã cổ phiếu là một kết quả vô cùng ấn tượng. Tuy nhiên, RMSE ở mức 7.29 USD (cao hơn LSTM) cho thấy dù tỷ lệ sai số phần trăm thấp, nhưng ở các mã cổ phiếu có thị giá cao, Random Forest vẫn có những khoảng lệch tuyệt đối đáng kể.

Sự thất bại của ARIMA: Sai số MAPE trung bình 32.24% và có những mã đạt mức kỷ lục 123.31%. Điều này khẳng định ARIMA không ổn định trước các đặc trưng phi tuyến tính và không thể đưa ra dự báo tin cậy trên một danh mục đa dạng.

5.4.2. Khả năng khái quát hóa và Quy mô

LSTM sẽ là lựa chọn tốt nhất cho quản trị rủi ro: Với RMSE thấp nhất, LSTM là công cụ tốt nhất để dự báo giá trị cụ thể, giúp nhà đầu tư xác định các điểm chặn lỗ (stop-loss) hoặc chốt lời (take-profit) một cách chính xác.

Random Forest phù hợp cho sàng lọc danh mục: Random Forest là công cụ lý tưởng để quét toàn bộ thị trường S&P 500 nhằm tìm ra các cổ phiếu có xu hướng tăng trưởng tiềm năng.

ARIMA chỉ mang tính tham khảo: Mô hình này chỉ nên được dùng như một phương pháp kiểm chứng (baseline) để làm nổi bật sự ưu việt của các kỹ thuật AI hiện đại, thay vì sử dụng độc lập trong đầu tư.

6. Kết luận và hướng phát triển

6.1. Kết luận

Tổng kết lại quá trình nghiên cứu, các mô hình, thuật toán trên đã làm sáng tỏ khả năng ứng

dụng mạnh mẽ của các kỹ thuật tiên tiến trong việc dự báo giá cổ phiếu dựa trên dữ liệu lịch sử của S&P 500.

Cụ thể, mô hình ARIMA đã bộc lộ những hạn chế đáng kể khi đối mặt với dữ liệu tài chính có tính phi tuyến và độ nhiễu cao, thể hiện qua mức sai số MAPE lên tới 32.24% và đường dự báo có xu hướng đi ngang, không phản ánh được thực tế biến động.

Ngược lại, mô hình LSTM đã chứng minh vị thế dẫn đầu về độ chính xác tuyệt đối với chỉ số MAPE chỉ dừng lại ở mức 3.10% và sai số RMSE cực thấp đạt 4.87 USD. Khả năng bám sát các biến động của thị trường và các điểm đảo chiều phức tạp của LSTM giúp nó trở thành công cụ đắc lực cho các nhà đầu tư cần dự báo giá trị chi tiết.

Bên cạnh đó, mô hình Random Forest cũng cho thấy hiệu năng cực kỳ ấn tượng với MAPE 3.79%. Biểu đồ thực nghiệm của Random Forest cho thấy sự ổn định và khả năng khái quát hóa cao trên toàn bộ danh mục.

6.2. Hướng phát triển đề tài

Mặc dù các kết quả đạt được là rất khả quan, tuy nhiên để tiến tới việc xây dựng một hệ thống dự báo toàn diện và có khả năng ứng dụng thực tế cao có thể áp dụng một số hướng phát triển sau:

Thứ nhất, cần mở rộng không gian đặc trưng và tích hợp dữ liệu phi cấu trúc, đặc biệt là phân tích tâm lý thị trường. Việc áp dụng NLP để khai thác tin tức tài chính, mạng xã hội và báo cáo doanh nghiệp, kết hợp với các chỉ báo kỹ thuật (RSI, MACD, Bollinger Bands) và yếu tố vĩ mô (lãi suất, lạm phát, tỷ giá) sẽ giúp mô hình nắm bắt tốt hơn các tín hiệu thị trường trước khi chúng phản ánh vào giá.

Thứ hai, nên phát triển các mô hình lai (Hybrid Models) nhằm tận dụng ưu điểm của nhiều kiến trúc, như CNN-LSTM hoặc ARIMA-LSTM, để xử lý đồng thời đặc trưng phi tuyến và chuỗi thời gian. Đồng thời, áp dụng tối ưu siêu tham số tự động (Bayesian Optimization, Genetic Algorithms) sẽ nâng cao hiệu quả và tính khách quan của mô hình.

Cuối cùng, hướng tới triển khai hệ thống dự báo thời gian thực, tích hợp API từ các sàn giao dịch để chuyển từ backtesting sang vận hành thực tế. Đây là nền tảng cho các hệ thống cảnh báo rủi ro và robot giao dịch tự động, giúp tận dụng tối đa giá trị của dự báo trong môi trường thị trường biến động nhanh.

TÀI LIỆU THAM KHẢO

Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.

Fischer, T., & Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2), 654-669.

Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780.

Tsay, R. S. (2005). *Analysis of Financial Time Series* (2nd ed.). Wiley-Interscience.

https://medium.com/@kapardhikannekanti/building-a-neural-network-from-scratch-the-long-short-term-memory-network-90d35a05b2af